

Análise do impacto de Oracles em diferentes níveis na acurácia de Sistemas de Múltiplos Classificadores

Relatório de resultados — respostas aos objetivos específicos

Subprojeto de Iniciação Científica

23 de agosto de 2026

Resumo

Este relatório responde, um a um, aos oito objetivos específicos do subprojeto, a partir de um experimento de $29 \text{ bases} \times 10 \text{ folds}$ estratificados $\times 3$ modos de geração de pool (870 folds, 0 erros), com pools de $M = 100$ classificadores. As medidas Oracle_1 a Oracle_M foram implementadas e verificadas; a monotonicidade $\text{Oracle}_1 \geq \text{Oracle}_2 \geq \dots \geq \text{Oracle}_M$ vale em 870/870 folds, assim como $\text{Oracle}_1 \geq$ votação majoritária. Os limites foram confrontados com a acurácia individual, a votação majoritária, a média de probabilidades e *doze* métodos de seleção dinâmica de classificadores e de *ensembles*.

Os três resultados centrais são: **(i)** nenhum nível intermediário de Oracle_N serve como limite superior realista *nos problemas binários* — o menor N em que Oracle_N cai abaixo da votação majoritária fica em $N \approx M/2$ nos três modos (mediana 52–53, Friedman $p = 0.40$), porque aí vale $\text{Oracle}_{M/2+1} \leq MVR \leq \text{Oracle}_{M/2}$, verificado em 660 de 660 folds binários; **(ii)** a folga $\text{Oracle}_1 - MVR$ é previsível *antes* de treinar qualquer método de seleção, pelo índice de redundância de erros DF/e^2 (Spearman -0.86 , $n = 87$); **(iii)** mesmo tomando o melhor de dez métodos dinâmicos escolhido *a posteriori* no teste, a seleção dinâmica recupera apenas 24.0%, 15.0% e 14.2% dessa folga — o Oracle_1 é um limite inatingível na prática, não uma meta. O relatório fecha com sete recomendações operacionais.

Sumário

1	Escopo e material	2
1.1	Protocolo	2
1.2	Definições usadas	2
2	Respostas aos objetivos específicos	3
2.1	Objetivo 1 — o Oracle como limite superior em DCS/DES	3
2.2	Objetivo 2 — implementação do Oracle tradicional	3
2.3	Objetivo 3 — generalização para Oracle_N	3
2.4	Objetivo 4 — construção dos pools	5
2.5	Objetivo 5 — avaliação experimental nas bases	5
2.6	Objetivo 6 — comparação com métodos reais	5
2.7	Objetivo 7 — níveis intermediários são um limite mais realista?	9
2.8	Objetivo 8 — recomendações e redução de custo	12
3	Confronto com os resultados esperados	13
4	Limitações	14
	Referências	14

1 Escopo e material

O experimento cujos números este relatório reporta é o run 2026-08-23T14-19-59_2286fcc, executado no commit 2286fcc. Toda tabela, figura e teste aqui pode ser reproduzido com

```
python scripts/run_experiment.py -full
python scripts/analyze_results.py results/experiments/<run>
```

e conferido contra `analysis.txt` e `analysis.json` gravados dentro do diretório do run. A análise textual completa, com o encadeamento dos achados, está em `docs/resultados-oracle-n.md`; este documento é o recorte que responde diretamente às perguntas do subprojeto.

1.1 Protocolo

Tabela 1: Protocolo experimental.

Item	Valor
Bases	29 (das 31 do catálogo; Ecoli e Glass excluídas pelo portão de viabilidade)
Validação	10-fold estratificado, <code>random_state=42</code>
Partição interna	treino / validação- <i>fitness</i> / DSEL, disjuntas
Tamanho do pool	$M = 100$ em todos os modos
Modos de pool	PGDCS-F1/T1 (Perceptron linear), Bagging (árvores), Random Forest
Fusores medidos	14 (MVR, combinação suave, 10 dinâmicos, 2 estáticos)
Métricas	acurácia, precisão e revocação macro, F1 macro, acurácia balanceada
Estatística	Friedman + Nemenyi (protocolo Demšar) e Wilcoxon pareado com Holm
Unidade pareada	a <i>base</i> (folds promediados antes do teste)
Total	870 folds, 0 erros, 4h08 de relógio

Duas bases foram excluídas por um portão de viabilidade explícito: a classe mais rara de Ecoli tem 2 instâncias e a de Glass tem 9, ambas abaixo dos 10 folds, o que impede a estratificação. A exclusão está registrada no manifesto do run com o motivo, e não é um descarte silencioso.

1.2 Definições usadas

Para um pool com M classificadores e uma amostra x ,

$$\text{Oracle}_N(x) = \mathbf{1} \left[\sum_{j=1}^M \mathbf{1}[h_j(x) = y(x)] \geq N \right], \quad N = 1, \dots, M, \quad (1)$$

de modo que Oracle_1 é o Oracle tradicional e vale $\text{Oracle}_1 \geq \text{Oracle}_2 \geq \dots \geq \text{Oracle}_M$.

Duas quantidades derivadas organizam o relatório:

Folga. $\text{Oracle}_1 - MVR$, a parcela do potencial anunciado pelo Oracle que a votação majoritária não converte.

Folga recuperada. $\frac{\text{melhor método dinâmico} - MVR}{\text{Oracle}_1 - MVR}$, a fração dessa folga que um método real alcança. O numerador usa o *máximo por fold* entre os dez métodos dinâmicos, escolhido no conjunto de teste: é um *oracle sobre métodos* e portanto uma cota superior generosa do que a seleção dinâmica entrega.

Uma terceira quantidade mede diversidade de forma comparável entre pools de força diferente. O Double Fault bruto (DF, a fração de pares que erram juntos) penaliza pools fracos por

construção, porque classificadores que erram mais erram juntos mais. Normalizando pelo valor esperado sob erros independentes,

$$DF/e^2, \quad e = 1 - \text{acurácia individual média}, \quad (2)$$

obtém-se um índice em que 1 significa erros independentes e valores altos significam redundância.

2 Respostas aos objetivos específicos

2.1 Objetivo 1 — o Oracle como limite superior em DCS/DES

Estudar o conceito de Oracle em MCS, com ênfase em sua utilização como medida de limite superior em técnicas de DCS e DES.

O Oracle é o seletor ideal: dada uma amostra, ele escolhe um classificador correto se existir algum no pool. Por isso é usado como cota superior de qualquer método de seleção — nenhum seletor real pode acertar uma amostra que *nenhum* membro do pool acerta. Souza e Cavalcanti (2017) documentam que essa cota é frouxa: técnicas DCS selecionam classificadores competentes para no máximo cerca de 85% das instâncias, mesmo com Oracle de 100% no treino.

O experimento reproduz e quantifica essa frouxidão nas 29 bases. O Oracle₁ médio fica entre 0.9951 e 0.9976 nos três modos — ou seja, *praticamente não discrimina entre pools*. A informação está na distância até os métodos reais, não no valor do Oracle. Esta é a motivação empírica direta da generalização proposta pelo subprojeto e o fio condutor das seções seguintes.

2.2 Objetivo 2 — implementação do Oracle tradicional

Implementar a medida tradicional de Oracle.

Implementado em `pos/oracle/`, sobre uma matriz de acertos binária $M \times n$ construída a partir das predições de cada classificador do pool. As verificações que sustentam a corretude:

- Oracle₁ $\geq$ votação majoritária em 870/870 **folds**. O Oracle tradicional nunca subestimou um método real de combinação — o que é uma propriedade necessária, e sua violação indicaria erro na matriz de acertos.
- Identidade de consistência, verificada com erro máximo 5.6×10^{-16} :

$$\frac{1}{M} \sum_{N=1}^M \text{Oracle}_N \equiv \text{acurácia individual média do pool}. \quad (3)$$

Ela decorre de $\sum_N P(\geq N \text{ corretos})/M = \mathbb{E}[\text{fração de classificadores corretos}]$ e liga a curva à matriz de acertos por dois caminhos independentes.

A identidade tem uma consequência metodológica que vale registrar: a “**área sob a curva Oracle_N**” **não é uma métrica nova**. Ela é a acurácia média dos classificadores-base sob outro nome, e não deve ser reportada como medida independente.

2.3 Objetivo 3 — generalização para Oracle_N

Propor e implementar a generalização do Oracle em diferentes níveis.

Implementada para todo $N = 1, \dots, M$, com a curva completa gravada por fold. A relação de monotonicidade Oracle₁ $\geq$ Oracle₂ $\geq \dots \geq$ Oracle_M — que é a definição da medida, não uma hipótese — foi verificada em 870/870 **folds**, **sem exceção**.

A tabela já antecipa o problema central do objetivo 7: entre $N = 1$ e $N = 5$ a curva cai apenas de 0.997 para 0.990, enquanto a votação majoritária está em 0.78–0.85. A faixa conservadora que o subprojeto procurava não está aqui.

Tabela 2: Níveis de Oracle e métodos reais, média sobre 29 bases $\times$ 10 folds.

Modo	Oracle ₁	Oracle ₂	Oracle ₅	Oracle _M	MVR	Comb. suave	Acc. indiv.
GA (Perceptron)	0.9976	0.9963	0.9905	0.1179	0.7784	0.7738	0.7052
Bagging	0.9951	0.9935	0.9884	0.3052	0.8467	0.8466	0.7931
Random Forest	0.9970	0.9958	0.9920	0.1725	0.8549	0.8546	0.7806




Figura 1: Curva Oracle_N no recorte $N = 1..10$, com a votação majoritária de cada modo. A distância vertical entre a curva e a linha tracejada correspondente é a folga. O GA lidera em $N = 1$, mas o Random Forest o ultrapassa a partir de $N = 3$: a vantagem do pool otimizado existe só na ponta mais otimista.

2.4 Objetivo 4 — construção dos pools

Construir pools com algoritmos simples e amplamente conhecidos, como Random Forest e Perceptron, induzindo diversidade por variações de treinamento.

Três modos, todos com $M = 100$:

PGDCS-F1/T1. Pool de Perceptrons lineares gerado por algoritmo genético que otimiza medidas de complexidade dos *bags* — é a estratégia que induz diversidade explicitamente. O nome traz o sufixo porque **não é o PGDCS completo**: a etapa em que o método *vota* quais medidas de complexidade convêm a cada base (`get_best_types`) foi desligada, e as medidas ficaram fixas em F1 e T1. Chamá-lo apenas de “PGDCS” convidaria a comparação errada com o artigo original. O efeito dessa simplificação é medido separadamente (ADR 0019).

Bagging. Árvores de decisão sobre reamostragens *bootstrap*.

Random Forest. Árvores com subamostragem adicional de atributos.

Os três atendem ao objetivo (algoritmos simples; diversidade por variação de subconjuntos de dados, de atributos e da própria seleção dos *bags*) e cobrem uma faixa larga de força do classificador-base, o que se mostrou determinante nas seções seguintes.

A medida de diversidade merece destaque porque o número bruto inverte a conclusão:

Tabela 3: Diversidade: o Double Fault bruto contra o índice normalizado.

Modo	Acc. individual	DF bruto	e^2 esperado	DF/ e^2
GA	0.7052	0.1566	0.0869	2.13
Random Forest	0.7806	0.1069	0.0482	2.92
Bagging	0.7931	0.1094	0.0428	3.98

Pelo DF bruto o GA seria o *menos* diverso (maior valor, 0.1566); pelo índice normalizado ele é o *mais* diverso (menor valor, 2.13; Friedman $p = 0.00009$, GA e RF empatados em *rank* e ambos à frente do Bagging). O DF absoluto sozinho leva ao diagnóstico errado, porque classificadores mais fracos erram mais e portanto erram juntos mais.

2.5 Objetivo 5 — avaliação experimental nas bases

Avaliar o comportamento dos níveis de Oracle em bases públicas de classificação.

Foram usadas 29 bases públicas (UCI, KEEL e as sintéticas clássicas da literatura de MCS: P2, Banana, Lithuanian), com 178 a 19 020 amostras, 2 a 8 classes e razão de desbalanceamento de 1.0 a 71.5.

Ressalva explícita. O objetivo 5 menciona preferência por *bases de imagens* públicas. O catálogo atual privilegia comparabilidade direta com a literatura de referência (as 28 bases de Monteiro et al., 2022, mais Magic) em vez de bases de imagens. É um desvio consciente do enunciado, registrado aqui e nas pendências do ROADMAP; incorporar bases de imagens é trabalho futuro imediato, e não altera nenhum dos mecanismos identificados, que dependem da geometria da fronteira e não do domínio.

2.6 Objetivo 6 — comparação com métodos reais

Comparar a acurácia estimada pelos níveis de Oracle com classificadores individuais e métodos reais de combinação (votação majoritária, média de probabilidades) e, quando viável, DCS/DES.

Foram medidos 14 fusores nos mesmos 870 folds, com DSEL disjunto e $k = 7$ vizinhos.




Figura 2: Folga $\text{Oracle}_1 - \text{MVR}$ por base. A dispersão entre bases (0.017 a 0.458) é muito maior que a dispersão entre modos (0.142 a 0.219): o potencial não explorado é sobretudo uma propriedade do problema, não da estratégia de geração.




Figura 3: Os 14 fusores contra o teto Oracle₁ (tracejado preto) e a acurácia individual média (pontilhado cinza), um painel por modo. A distância da barra mais alta até a linha tracejada é a parte do potencial do pool que nenhum método alcançou. Barra ausente = método inaplicável ao pool.

Tabela 4: Acurácia média dos 14 fusores contra o teto Oracle₁. Traço = método que exige `predict_proba`, indisponível no Perceptron linear.

Fusor	GA	Bagging	Random Forest
Votação majoritária (MVR)	0.7784	0.8467	0.8549
Combinação suave	0.7738	0.8466	0.8546
OLA	0.7829	0.8028	0.7915
LCA	0.7271	0.7878	0.7863
MCB	0.7828	0.7943	0.7900
Rank	0.7760	0.8022	0.7908
KNORA-E	0.7897	0.8261	0.8274
KNORA-U	0.8056	0.8468	0.8564
DES-P	0.8021	0.8481	0.8566
DES-KNN	0.7995	0.8477	0.8492
META-DES	—	0.8482	0.8545
KNOP	—	0.8486	0.8556
Melhor individual (estático)	0.7630	0.7999	0.7958
Seleção estática	0.7797	0.8475	0.8546
Melhor por fold (<i>oracle</i> sobre métodos)	0.8340	0.8688	0.8733
Acurácia individual média	0.7052	0.7931	0.7806
Oracle ₁	0.9976	0.9951	0.9970
Folga Oracle ₁ – MVR	0.2192	0.1484	0.1421
Folga recuperada	24.0%	15.0%	14.2%

(a) **O melhor pool produz a pior votação.** O GA tem o *maior* Oracle₁ de todos (0.9976) e a *menor* votação majoritária de todas (0.7784). A folga resultante, 0.2192, é 54% maior que a do Random Forest (Friedman $p = 0.0045$; GA *vs* RF acima da diferença crítica, Wilcoxon $p = 0.0003$). Em P2 o pool contém um classificador correto para *toda* amostra de teste (Oracle₁ = 1.0000), os erros são praticamente independentes ($DF/e^2 = 1.02$) e a votação majoritária entrega 0.5420. Não é falta de informação no pool — é o fusor que não a extrai.

(b) **A combinação suave não supera a votação majoritária em nenhum modo.** Nos pools de árvores as duas regras empatam (Δ da ordem de 10^{-4} ; dão o mesmo resultado em 278 e 275 dos 290 folds). No pool de Perceptrons a combinação suave é pior em média (-0.0046), mas a diferença **não é estatisticamente significativa** ($p = 0.51$). A conclusão que se sustenta é a negativa: para pools de classificadores lineares a média de margens normalizadas não é o método real a bater — o MVR é.

(c) **O eixo que organiza a seleção dinâmica é a poda.** O resultado mais robusto do experimento não é sobre a folga, é sobre o custo de descartar membros do pool. Testando cada fusor contra o MVR por base ($N = 29$), com correção de Holm para a família de 13 testes:

Em Bagging o padrão é idêntico: OLA, LCA, MCB e Rank perdem em 27–28 das 28 bases, com Δ entre -0.044 e -0.059 e $p_{\text{Holm}} \leq 0.0001$. A escala é clara:

- podar até *um* classificador (OLA, LCA, MCB, Rank, melhor individual) → perda de 0.044 a 0.069 nos pools de árvores, sempre significativa;
- podar parcialmente (KNORA-E) → perda intermediária, ainda significativa;
- não podar, apenas reponderar (KNORA-U, DES-P, META-DES, KNOP, seleção estática) → empate técnico com o MVR.

Tabela 5: Fusores contra o MVR no pool Random Forest (Wilcoxon pareado, Holm).

Fusor	Média	Δ vs MVR	Vitórias/derrotas	p (Holm)
LCA	0.7863	-0.0686	0/29	< 0.001
MCB	0.7900	-0.0649	0/29	< 0.001
Rank	0.7908	-0.0641	0/29	< 0.001
OLA	0.7915	-0.0634	0/29	< 0.001
Melhor individual	0.7958	-0.0592	1/28	< 0.001
KNORA-E	0.8274	-0.0275	3/24	0.0004
DES-KNN	0.8492	-0.0057	10/18	0.097
KNORA-U	0.8564	+0.0015	19/6	0.31
DES-P	0.8566	+0.0017	13/9	0.84
KNOP	0.8556	+0.0006	13/12	1.00
META-DES	0.8545	-0.0005	13/15	1.00
Seleção estática	0.8546	-0.0003	14/12	1.00
Combinação suave	0.8546	-0.0003	1/2	1.00

Os dois métodos estáticos confirmam o eixo pelos extremos: a seleção estática, que mantém o pool inteiro, empata com o MVR nos três modos; o melhor individual, que é poda máxima sem nenhuma localidade, está entre os piores em todos.

(d) Onde a seleção dinâmica de fato paga. No pool de Perceptrons a ordem se inverte parcialmente: **KNORA-U é o único fusor que supera o MVR de forma estatisticamente sustentada em algum modo** (+0.0272, $p_{\text{Holm}} = 0.0045$, vencendo em 147 dos 290 folds contra 49 derrotas e 94 empates). Nos pools de árvores o mesmo método fica em +0.0001 e +0.0015, sem significância.

A vantagem se concentra nas bases de fronteira não-linear em baixa dimensão: em P2, Lithuanian e Banana a recuperação média do GA é 0.766, contra 0.157 do Bagging e 0.155 do Random Forest nas mesmas bases. O mecanismo é geométrico: um Perceptron não separa a espiral do P2, mas separa qualquer vizinhança dela, e escolher o Perceptron certo por região é exatamente o que falta. Uma árvore já resolve a fronteira sozinha, então o voto majoritário já está perto do que o pool consegue e não sobra folga *local* a extrair.

(e) O viés de estimação foi medido, não apenas discutido. Numa versão anterior do protocolo o DSEL da seleção dinâmica era a mesma partição que o GA usa na função de *fitness*, o que favorecia o GA por construção. O protocolo atual separa as duas partições. Isolar o viés exige separar dois efeitos simultâneos — o viés removido (só afeta o GA) e o DSEL pela metade (afeta os três modos) — e Bagging e RF servem de grupo de controle, porque mantêm os pools *bit-idênticos* entre os dois desenhos (verificado: $\max |\Delta| = 0.000000$ em toda coluna de pool e curva Oracle idêntica em 290/290 folds de cada modo).

Pela diferença-em-diferenças, restrita aos cinco métodos comuns aos dois desenhos: o controle perdeu -0.0057 de folga recuperada, o GA perdeu -0.0003, logo o viés é +0.0055 — cerca de 3% relativos, e nenhum dos deltas é significativo. O desenho anterior **não** estava inflando materialmente a vantagem do GA; a correção está feita e é a que vale, mas não muda conclusão alguma.

2.7 Objetivo 7 — níveis intermediários são um limite mais realista?

Analisar se níveis intermediários de Oracle podem representar estimativas de limite superior mais conservadoras e mais próximas do desempenho de métodos reais.

A resposta é não, e o experimento identifica a razão estrutural.

Defina N^* como o menor N tal que $\text{Oracle}_N < \text{votação majoritária}$ — o nível em que o Oracle deixa de ser otimista.

Tabela 6: N^* por modo, com $M = 100$.

Modo	Mediana	IQR	Média	Folds com $N^* > 50$
GA	52	[51, 55]	51.9	79.3%
Bagging	53	[51, 56]	54.4	81.4%
Random Forest	53	[51, 56]	53.0	79.3%

Friedman $p = 0.40$: **os três modos têm o mesmo N^* , e ele fica em $N \approx M/2$** . Não é coincidência empírica. O mecanismo não é a identidade $\text{Oracle}_{M/2+1} \equiv MVR$ — essa afirmação, feita em versões anteriores, é falsa — mas um *sanduíche*:

$$\text{Oracle}_{M/2+1} \leq MVR \leq \text{Oracle}_{M/2}. \quad (4)$$

A votação acerta sempre que mais da metade do pool acerta, logo $MVR \geq \text{Oracle}_{51}$; e ela só pode ganhar, além disso, os empates 50–50, logo nunca passa de Oracle_{50} . O sanduíche foi verificado em **660 de 660** folds binários, mas a igualdade $MVR = \text{Oracle}_{51}$ vale em apenas 508 deles (77%): nos demais 23% os empates são desfeitos a favor, com excesso médio de +0.0035.

A distinção não é um detalhe — é ela que dá o valor de N^* . Como N^* é o primeiro nível *estritamente* abaixo do MVR, e $\text{Oracle}_{51} = MVR$ não satisfaz “<”, os empates empurram N^* de 51 para 52 ou mais, que é exatamente onde as medianas caem.

O limite é do caso binário. 22 das 29 bases são binárias. Nas 7 multiclasse a votação é por pluralidade e um classificador correto não precisa de 51 votos para vencer, então o sanduíche não vale — e N^* desce de forma significativa:

Tabela 7: N^* mediano por cardinalidade de classes.

grupo	bases	GA	Bagging	RF
binárias	22	53.4	53.7	53.5
multiclasse	7	44.4	48.1	47.3

Mediana 53.7 contra 47.6, Mann-Whitney $p = 2.7 \times 10^{-6}$. Dentro de cada grupo os modos continuam empatados ($p = 0.71$ e $p = 0.37$).

Disso decorre a resposta ao objetivo, **restrita aos problemas binários**:

- Para $N \ll M/2$ a curva está **saturada**: os três modos ficam entre 0.988 e 0.998 em $N = 1..5$, e $\text{Oracle}_5 \geq MVR$ em 100% dos 870 folds. As diferenças entre modos são estatisticamente reais ($p < 0.001$) mas de magnitude 0.002–0.004. Mais conservador que Oracle_1 , sim; perto de um método real, não.
- Para $N \approx M/2$ a curva **já é** a votação majoritária, sob outro nome. Não acrescenta informação.
- **Não existe faixa intermediária útil** entre as duas.

O que substitui a ideia original. O objetivo 7 buscava uma estimativa conservadora e alcançável. Ela existe, mas não é “ Oracle_N para algum N ”; é a folga $\text{Oracle}_1 - MVR$ ponderada pela fração dela que métodos reais recuperam. Medido: mesmo tomando o melhor de dez métodos




Figura 4: Distribuição de N^* . A concentração em torno de $M/2$ nos três modos é o que impede qualquer nível intermediário de servir como limite realista.

dinâmicos escolhido *a posteriori* no teste, a recuperação fica em 24.0% (GA), 15.0% (Bagging) e 14.2% (RF), com medianas bem menores (0.167, 0.108, 0.091) e recuperação *exatamente zero* no primeiro quartil de Bagging e RF.

Correção. Versões anteriores apresentavam

$$MVR + 0.15 (\text{Oracle}_1 - MVR) \quad (5)$$

como “limite superior operacional”. Não é um limite: 0.15 é a recuperação *média* dos pools de árvore, e uma média é ultrapassada por metade da massa. Medido nos folds de árvore, 37.7% deles recuperam mais que 0.15. A expressão é uma **estimativa**, $\widehat{\text{Acc}}_{DS}$, e deve ser lida como tal.

Quem quiser de fato uma cota precisa de um quantil alto da distribuição de R = recuperação, não da sua média:

$$\widehat{\text{Acc}}_{DS} = MVR + \bar{R} (\text{Oracle}_1 - MVR), \quad \text{cota}_{95} = MVR + Q_{0.95}(R) (\text{Oracle}_1 - MVR), \quad (6)$$

com $Q_{0.95}(R) = 0.50$ nos pools de árvore — mais de três vezes a média. E os dois números descrevem a mesma distribuição em que 31% dos folds recuperam *nada* ($R \leq 0$). Ambos permanecem otimistas, porque R é medido escolhendo o melhor método no próprio teste.

Robustez à métrica. A metodologia do subprojeto pede precisão, revocação, F1 e acurácia balanceada além da acurácia — a preocupação legítima sendo que a acurácia bruta esconda a classe minoritária, num catálogo que chega a IMB 71.5. As quatro métricas foram gravadas para *todo* fusor. Em acurácia balanceada tudo cai, mas de forma quase uniforme, e a folga *cresce*:

Tabela 8: Acurácia *versus* acurácia balanceada.

Modo	Oracle ₁	Oracle ₁ balanc.	MVR	MVRbalanc.	Folga	Folga balanc.
GA	0.9976	0.9967	0.7784	0.7368	0.2192	0.2599
Bagging	0.9951	0.9923	0.8467	0.8163	0.1484	0.1760
Random Forest	0.9970	0.9949	0.8549	0.8214	0.1421	0.1735

O Oracle₁ é quase insensível ao desbalanceamento — basta *um* classificador do pool acertar a instância minoritária — enquanto o MVR precisa que 51 acertem, e é aí que a minoria se perde.

Nos *ranks* de fusor a única mudança sistemática é o DCS puro melhorar 0.3–0.4 posições (OLA vai de *rank* 6.38 para 6.00 no RF), o que faz sentido — escolher o competente na vizinhança ajuda numa região minoritária. Mas em nenhum modo isso muda o topo: KNORA-U, META-DES, MVR e combinação suave continuam empatados na frente, e OLA e LCA continuam no fundo. **Nenhuma conclusão deste relatório depende da escolha da métrica.**

2.8 Objetivo 8 — recomendações e redução de custo

Gerar recomendações sobre o uso de Oracles em diferentes níveis como ferramenta de análise prévia do potencial de desempenho de ensembles, considerando a redução de custo computacional.

A base quantitativa da recomendação é que o índice de redundância prevê a folga *antes* de treinar qualquer método de seleção:

$$\text{Spearman}(\text{DF}/e^2, \text{Oracle}_1 - \text{MVR}) = -0.860, \quad p = 8 \times 10^{-27}, \quad n = 87. \quad (7)$$

Por modo: GA -0.933 , Bagging -0.909 , RF -0.785 . O índice custa $O(M^2n)$ sobre a matriz de acertos que já se tem.




Figura 5: À esquerda, a distribuição da folga recuperada por modo. À direita, a mesma quantidade contra DF/e^2 : a correlação que prevê o *tamanho* da folga não prevê a *fração alcançável*.

As sete recomendações que o experimento sustenta:

1. **Use $\text{Oracle}_1 - \text{MVR}$ como medida de potencial, não Oracle_1 como meta.** O Oracle_1 fica entre 0.995 e 0.998 nos três modos e 29 bases: não discrimina. A folga discrimina (0.142 a 0.219 entre modos; 0.017 a 0.458 entre bases).
2. **Não procure um Oracle_N intermediário como limite realista.** N^* fica em $N \approx M/2$ nos três modos (Friedman $p = 0.40$). Reporte Oracle_1 , a folga e N^* como diagnóstico; não reporte um nível intermediário como cota.
3. **Calcule DF/e^2 antes de treinar qualquer método de seleção.** Regra operacional medida neste experimento:

DF/e^2	Folga típica	Decisão
≥ 4	< 0.05	não vale DCS/DES — o custo não se paga
2–4	0.05–0.15	marginal; só KNORA-U ou DES-P, sem esperar ganho
≈ 1	> 0.30	candidato forte, sobretudo com base fraco

Extremos observados: Thyroid (DF/ e^2 entre 6.96 e 8.58, folga 0.035) contra P2 (DF/ $e^2 = 1.02$, folga 0.458).

Os cortes foram validados fora da amostra, porque descobri-los e avaliá-los nas mesmas 29 bases seria circular. Reajustando os dois limiares em 28 bases e prevendo a 29ª, 29 vezes: acerto 0.805 contra 0.736 da regra trivial, e os limiares reajustados caem na mediana em 1.14 e 4.82 — praticamente os ≈ 1 e ≥ 4 da tabela. A regra generaliza; a margem sobre o baseline é de sete pontos, não de uma ordem de grandeza, porque a faixa do meio domina o catálogo (64 dos 87 pares base×modo).

Sobre o denominador. e^2 com e médio só é o valor esperado sob independência se todos os classificadores errarem na mesma taxa; o exato é $\frac{2}{M(M-1)} \sum_{i < j} e_i e_j$. Recalculado a partir das acurácias individuais já gravadas por fold, o índice exato **não muda a conclusão**: Spearman agrupado passa de -0.8603 para -0.8607 . A razão entre os dois tem mediana 1.0005, porque o desvio das acurácias dentro de um pool é pequeno (0.054 em média). A correção vale por rigor, não por resultado.

4. **DF/ e^2 não prevê o que você vai recuperar.** Ele prevê a folga, não a fração alcançável (por base $\rho = +0.19$, $p = 0.074$; por fold $\rho = +0.02$, $p = 0.59$). São perguntas distintas. Para prever recuperação, o preditor que funcionou é qualitativo: fronteira não-linear em baixa dimensão *mais* classificador-base fraco.
5. **Se for usar seleção dinâmica, use um método que não pode o pool.** OLA, LCA, MCB, Rank e o melhor individual perdem de 0.044 a 0.069 contra o MVR nos pools de árvores, em 27–29 das 29 bases, com $p_{\text{Holm}} < 0.001$. KNORA-U é o único que supera o MVR de forma sustentada em algum modo e nunca perde em nenhum.
6. **Em pool homogêneo forte (Bagging, Random Forest) a decisão padrão é não usar DCS/DES.** Nenhum dos 13 fusores supera a votação majoritária de forma significativa em nenhum dos dois modos. O melhor caso é $+0.0019$ (KNOP em Bagging), que não sobrevive a Holm. O MVR é grátis; os outros não.
7. **O custo foi medido, não estimado.** Passar de 5 para 12 métodos de seleção levou o experimento de 2h21 para 4h08 de relógio nas mesmas 29 bases $\times$ 10 folds $\times$ 3 modos — fator $1.76\times$. Combinado com a recomendação 6: o custo marginal de DCS/DES é da ordem do custo de gerar os pools, e num pool de árvores ele compra zero.

3 Confronto com os resultados esperados

Esperado no projeto	Obtido
Caracterizar quantitativamente Oracle _N em múltiplos níveis e construir a curva.	Confirmado. Curva completa $N = 1..M$ por fold, monotonicidade em 870/870, e a identidade que liga a média da curva à acurácia individual.
Verificar se níveis intermediários se aproximam de métodos práticos.	Refutado , com mecanismo identificado: $N^* \approx M/2$ porque Oracle _{$M/2+1$} $\equiv$ MVR em problema binário. Abaixo disso a curva está saturada. Resultado negativo, mas informativo — fecha a pergunta em vez de deixá-la em aberto.
Implementação reproduzível de Oracle ₁ ..Oracle _M , com scripts de treino, matriz de acertos, métricas e gráficos.	Entregue. Manifesto por fold com <i>git SHA</i> , versões de dependências e sementes; 8 figuras e testes estatísticos gerados por um único comando.

Esperado no projeto	Obtido
Relacionar diversidade, redundância de acertos e desempenho.	Entregue e quantificado: DF/e^2 prevê a folga com $\rho = -0.86$ ($n = 87$), e o mesmo índice <i>não</i> prevê a fração recuperável — distinção que não estava antecipada no projeto.
Indicar em que cenários o Oracle tradicional superestima o desempenho alcançável.	Entregue: superestima sempre, e mais ainda em pools diversos de base fraco. Entre 76% e 86% da folga anunciada não é recuperada nem pelo melhor de dez métodos escolhido no teste.
Apoiar a decisão sobre usar métodos complexos de seleção.	Entregue como as sete recomendações operacionais, com um limiar numérico em DF/e^2 e um critério qualitativo para prever recuperação.

4 Limitações

- **Bases de imagens.** O objetivo 5 as menciona como preferência; o catálogo atual privilegia comparabilidade com a literatura de referência. É a pendência mais direta.
- **$M = 100$ fixo.** Todas as conclusões sobre N^* são relativas a $M = 100$. O argumento estrutural ($\text{Oracle}_{M/2+1} \equiv MVR$ em problema binário) é independente de M , mas a verificação empírica não varreu M .
- **Dois métodos ausentes no pool do GA.** META-DES e KNOP exigem `predict_proba`, indisponível no Perceptron linear. As colunas ficam vazias com o motivo gravado por fold, e as comparações entre modos que os envolvem foram restritas aos modos aplicáveis — não houve imputação.
- **“Melhor por fold” é otimista.** A métrica de folga recuperada usa o máximo entre métodos escolhido no conjunto de teste. Um seletor de método honesto entregaria menos. Os números de recuperação são cotas superiores.
- **Poder estatístico com 14 fusores.** A diferença crítica de Nemenyi cresce com o número de colunas a ponto de nada ser significativo. Por isso o protocolo mantém um conjunto primário de 7 métodos para Friedman/Nemenyi e trata os demais em camada descritiva, com Wilcoxon pareado contra o MVR e correção de Holm.

Referências

- CRUZ, R. M. O.; SABOURIN, R.; CAVALCANTI, G. D. C. Dynamic classifier selection: Recent advances and perspectives. *Information Fusion*, v. 41, p. 195–216, 2018.
- CRUZ, R. M. O.; SABOURIN, R.; CAVALCANTI, G. D. C. META-DES.Oracle: Meta-learning and feature selection for dynamic ensemble selection. *Information Fusion*, v. 38, p. 84–103, 2017.
- DEMŠAR, J. Statistical Comparisons of Classifiers over Multiple Data Sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- KUNCHEVA, L. I.; WHITAKER, C. J. Measures of Diversity in Classifier Ensembles and Their Relationship with the Ensemble Accuracy. *Machine Learning*, v. 51, p. 181–207, 2003.

SOUZA, M. A.; CAVALCANTI, G. D. C. On the Characterization of the Oracle for Dynamic Classifier Selection. In: *IJCNN*, 2017, Anchorage. p. 332–339.