

# Análise do impacto de Oracles em diferentes níveis na acurácia de Sistemas de Múltiplos Classificadores

## Relatório de resultados — respostas aos objetivos específicos

Subprojeto de Iniciação Científica

23 de agosto de 2026

### Resumo

Este relatório responde, um a um, aos oito objetivos específicos do subprojeto, a partir de um experimento de 29 bases  $\times$  10 folds estratificados  $\times$  3 modos de geração de pool (870 folds, 0 erros), com pools de  $M = 100$  classificadores. As medidas  $\text{Oracle}_1$  a  $\text{Oracle}_M$  foram implementadas e verificadas; a monotonicidade  $\text{Oracle}_1 \geq \text{Oracle}_2 \geq \dots \geq \text{Oracle}_M$  vale em 870/870 folds, assim como  $\text{Oracle}_1 \geq$  votação majoritária. Os limites foram confrontados com a acurácia individual, a votação majoritária, a média de probabilidades e *doze* métodos de seleção dinâmica de classificadores e de *ensembles*.

Os três resultados centrais são: **(i)** nenhum nível intermediário de  $\text{Oracle}_N$  serve como limite superior realista — o menor  $N$  em que  $\text{Oracle}_N$  cai abaixo da votação majoritária fica em  $N \approx M/2$  nos três modos (mediana 52–53, Friedman  $p = 0.40$ ), porque em problema binário  $\text{Oracle}_{M/2+1}$  é, por construção, a própria votação majoritária; **(ii)** a folga  $\text{Oracle}_1 - MVR$  é previsível *antes* de treinar qualquer método de seleção, pelo índice de redundância de erros  $DF/e^2$  (Spearman  $-0.86$ ,  $n = 87$ ); **(iii)** mesmo tomando o melhor de dez métodos dinâmicos escolhido *a posteriori* no teste, a seleção dinâmica recupera apenas 24.0%, 15.0% e 14.2% dessa folga — o  $\text{Oracle}_1$  é um limite inatingível na prática, não uma meta. O relatório fecha com sete recomendações operacionais.

## Sumário

|          |                                                                           |           |
|----------|---------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Escopo e material</b>                                                  | <b>2</b>  |
| 1.1      | Protocolo . . . . .                                                       | 2         |
| 1.2      | Definições usadas . . . . .                                               | 2         |
| <b>2</b> | <b>Respostas aos objetivos específicos</b>                                | <b>3</b>  |
| 2.1      | Objetivo 1 — o Oracle como limite superior em DCS/DES . . . . .           | 3         |
| 2.2      | Objetivo 2 — implementação do Oracle tradicional . . . . .                | 3         |
| 2.3      | Objetivo 3 — generalização para $\text{Oracle}_N$ . . . . .               | 3         |
| 2.4      | Objetivo 4 — construção dos pools . . . . .                               | 5         |
| 2.5      | Objetivo 5 — avaliação experimental nas bases . . . . .                   | 5         |
| 2.6      | Objetivo 6 — comparação com métodos reais . . . . .                       | 5         |
| 2.7      | Objetivo 7 — níveis intermediários são um limite mais realista? . . . . . | 9         |
| 2.8      | Objetivo 8 — recomendações e redução de custo . . . . .                   | 11        |
| <b>3</b> | <b>Confronto com os resultados esperados</b>                              | <b>12</b> |
| <b>4</b> | <b>Limitações</b>                                                         | <b>13</b> |
|          | <b>Referências</b>                                                        | <b>13</b> |

# 1 Escopo e material

O experimento cujos números este relatório reporta é o run 2026-08-23T14-19-59\_2286fcc, executado no commit 2286fcc. Toda tabela, figura e teste aqui pode ser reproduzido com

```
python scripts/run_experiment.py -full
python scripts/analyze_results.py results/experiments/<run>
```

e conferido contra `analysis.txt` e `analysis.json` gravados dentro do diretório do run. A análise textual completa, com o encadeamento dos achados, está em `docs/resultados-oracle-n.md`; este documento é o recorte que responde diretamente às perguntas do subprojeto.

## 1.1 Protocolo

Tabela 1: Protocolo experimental.

| Item             | Valor                                                                       |
|------------------|-----------------------------------------------------------------------------|
| Bases            | 29 (das 31 do catálogo; Ecoli e Glass excluídas pelo portão de viabilidade) |
| Validação        | 10-fold estratificado, <code>random_state=42</code>                         |
| Partição interna | treino / validação- <i>fitness</i> / DSEL, disjuntas                        |
| Tamanho do pool  | $M = 100$ em todos os modos                                                 |
| Modos de pool    | GA (PGDCS, Perceptron linear), Bagging (árvores), Random Forest             |
| Fusores medidos  | 14 (MVR, combinação suave, 10 dinâmicos, 2 estáticos)                       |
| Métricas         | acurácia, precisão e revocação macro, F1 macro, acurácia balanceada         |
| Estatística      | Friedman + Nemenyi (protocolo Demšar) e Wilcoxon pareado com Holm           |
| Unidade pareada  | a <i>base</i> (folds promediados antes do teste)                            |
| Total            | 870 folds, 0 erros, 4h08 de relógio                                         |

Duas bases foram excluídas por um portão de viabilidade explícito: a classe mais rara de Ecoli tem 2 instâncias e a de Glass tem 9, ambas abaixo dos 10 folds, o que impede a estratificação. A exclusão está registrada no manifesto do run com o motivo, e não é um descarte silencioso.

## 1.2 Definições usadas

Para um pool com  $M$  classificadores e uma amostra  $x$ ,

$$\text{Oracle}_N(x) = \mathbf{1} \left[ \sum_{j=1}^M \mathbf{1}[h_j(x) = y(x)] \geq N \right], \quad N = 1, \dots, M, \quad (1)$$

de modo que  $\text{Oracle}_1$  é o Oracle tradicional e vale  $\text{Oracle}_1 \geq \text{Oracle}_2 \geq \dots \geq \text{Oracle}_M$ .

Duas quantidades derivadas organizam o relatório:

**Folga.**  $\text{Oracle}_1 - MVR$ , a parcela do potencial anunciado pelo Oracle que a votação majoritária não converte.

**Folga recuperada.**  $\frac{\text{melhor método dinâmico} - MVR}{\text{Oracle}_1 - MVR}$ , a fração dessa folga que um método real alcança. O numerador usa o *máximo por fold* entre os dez métodos dinâmicos, escolhido no conjunto de teste: é um *oracle sobre métodos* e portanto uma cota superior generosa do que a seleção dinâmica entrega.

Uma terceira quantidade mede diversidade de forma comparável entre pools de força diferente. O Double Fault bruto (DF, a fração de pares que erram juntos) penaliza pools fracos por

construção, porque classificadores que erram mais erram juntos mais. Normalizando pelo valor esperado sob erros independentes,

$$DF/e^2, \quad e = 1 - \text{acurácia individual média}, \quad (2)$$

obtém-se um índice em que 1 significa erros independentes e valores altos significam redundância.

## 2 Respostas aos objetivos específicos

### 2.1 Objetivo 1 — o Oracle como limite superior em DCS/DES

*Estudar o conceito de Oracle em MCS, com ênfase em sua utilização como medida de limite superior em técnicas de DCS e DES.*

O Oracle é o seletor ideal: dada uma amostra, ele escolhe um classificador correto se existir algum no pool. Por isso é usado como cota superior de qualquer método de seleção — nenhum seletor real pode acertar uma amostra que *nenhum* membro do pool acerta. Souza e Cavalcanti (2017) documentam que essa cota é frouxa: técnicas DCS selecionam classificadores competentes para no máximo cerca de 85% das instâncias, mesmo com Oracle de 100% no treino.

O experimento reproduz e quantifica essa frouxidão nas 29 bases. O Oracle<sub>1</sub> médio fica entre 0.9951 e 0.9976 nos três modos — ou seja, *praticamente não discrimina entre pools*. A informação está na distância até os métodos reais, não no valor do Oracle. Esta é a motivação empírica direta da generalização proposta pelo subprojeto e o fio condutor das seções seguintes.

### 2.2 Objetivo 2 — implementação do Oracle tradicional

*Implementar a medida tradicional de Oracle.*

Implementado em `pos/oracle/`, sobre uma matriz de acertos binária  $M \times n$  construída a partir das predições de cada classificador do pool. As verificações que sustentam a corretude:

- Oracle<sub>1</sub>  $\geq$  votação majoritária em 870/870 **folds**. O Oracle tradicional nunca subestimou um método real de combinação — o que é uma propriedade necessária, e sua violação indicaria erro na matriz de acertos.
- Identidade de consistência, verificada com erro máximo  $5.6 \times 10^{-16}$ :

$$\frac{1}{M} \sum_{N=1}^M \text{Oracle}_N \equiv \text{acurácia individual média do pool}. \quad (3)$$

Ela decorre de  $\sum_N P(\geq N \text{ corretos})/M = \mathbb{E}[\text{fração de classificadores corretos}]$  e liga a curva à matriz de acertos por dois caminhos independentes.

A identidade tem uma consequência metodológica que vale registrar: a “**área sob a curva Oracle<sub>N</sub>**” **não é uma métrica nova**. Ela é a acurácia média dos classificadores-base sob outro nome, e não deve ser reportada como medida independente.

### 2.3 Objetivo 3 — generalização para Oracle<sub>N</sub>

*Propor e implementar a generalização do Oracle em diferentes níveis.*

Implementada para todo  $N = 1, \dots, M$ , com a curva completa gravada por fold. A relação de monotonicidade Oracle<sub>1</sub>  $\geq$  Oracle<sub>2</sub>  $\geq \dots \geq$  Oracle<sub>M</sub> — que é a definição da medida, não uma hipótese — foi verificada em 870/870 **folds**, **sem exceção**.

A tabela já antecipa o problema central do objetivo 7: entre  $N = 1$  e  $N = 5$  a curva cai apenas de 0.997 para 0.990, enquanto a votação majoritária está em 0.78–0.85. A faixa conservadora que o subprojeto procurava não está aqui.

Tabela 2: Níveis de Oracle e métodos reais, média sobre 29 bases  $\times$  10 folds.

| Modo            | Oracle <sub>1</sub> | Oracle <sub>2</sub> | Oracle <sub>5</sub> | Oracle <sub>M</sub> | MVR           | Comb. suave | Acc. indiv. |
|-----------------|---------------------|---------------------|---------------------|---------------------|---------------|-------------|-------------|
| GA (Perceptron) | <b>0.9976</b>       | 0.9963              | 0.9905              | 0.1179              | 0.7784        | 0.7738      | 0.7052      |
| Bagging         | 0.9951              | 0.9935              | 0.9884              | <b>0.3052</b>       | 0.8467        | 0.8466      | 0.7931      |
| Random Forest   | 0.9970              | <b>0.9958</b>       | <b>0.9920</b>       | 0.1725              | <b>0.8549</b> | 0.8546      | 0.7806      |




Figura 1: Curva Oracle<sub>N</sub> no recorte  $N = 1..10$ , com a votação majoritária de cada modo. A distância vertical entre a curva e a linha tracejada correspondente é a folga. O GA lidera em  $N = 1$ , mas o Random Forest o ultrapassa a partir de  $N = 3$ : a vantagem do pool otimizado existe só na ponta mais otimista.

## 2.4 Objetivo 4 — construção dos pools

*Construir pools com algoritmos simples e amplamente conhecidos, como Random Forest e Perceptron, induzindo diversidade por variações de treinamento.*

Três modos, todos com  $M = 100$ :

**GA (PGDCS).** Pool de Perceptrons lineares gerado por algoritmo genético que otimiza medidas de complexidade dos *bags* — é a estratégia que induz diversidade explicitamente.

**Bagging.** Árvores de decisão sobre reamostragens *bootstrap*.

**Random Forest.** Árvores com subamostragem adicional de atributos.

Os três atendem ao objetivo (algoritmos simples; diversidade por variação de subconjuntos de dados, de atributos e da própria seleção dos *bags*) e cobrem uma faixa larga de força do classificador-base, o que se mostrou determinante nas seções seguintes.

A medida de diversidade merece destaque porque o número bruto inverte a conclusão:

Tabela 3: Diversidade: o Double Fault bruto contra o índice normalizado.

| Modo          | Acc. individual | DF bruto | $e^2$ esperado | DF/ $e^2$   |
|---------------|-----------------|----------|----------------|-------------|
| GA            | 0.7052          | 0.1566   | 0.0869         | <b>2.13</b> |
| Random Forest | 0.7806          | 0.1069   | 0.0482         | 2.92        |
| Bagging       | 0.7931          | 0.1094   | 0.0428         | 3.98        |

Pelo DF bruto o GA seria o *menos* diverso (maior valor, 0.1566); pelo índice normalizado ele é o *mais* diverso (menor valor, 2.13; Friedman  $p = 0.00009$ , GA e RF empatados em *rank* e ambos à frente do Bagging). O DF absoluto sozinho leva ao diagnóstico errado, porque classificadores mais fracos erram mais e portanto erram juntos mais.

## 2.5 Objetivo 5 — avaliação experimental nas bases

*Avaliar o comportamento dos níveis de Oracle em bases públicas de classificação.*

Foram usadas 29 bases públicas (UCI, KEEL e as sintéticas clássicas da literatura de MCS: P2, Banana, Lithuanian), com 178 a 19 020 amostras, 2 a 8 classes e razão de desbalanceamento de 1.0 a 71.5.

**Ressalva explícita.** O objetivo 5 menciona preferência por *bases de imagens* públicas. O catálogo atual privilegia comparabilidade direta com a literatura de referência (as 28 bases de Monteiro et al., 2022, mais Magic) em vez de bases de imagens. É um desvio consciente do enunciado, registrado aqui e nas pendências do ROADMAP; incorporar bases de imagens é trabalho futuro imediato, e não altera nenhum dos mecanismos identificados, que dependem da geometria da fronteira e não do domínio.

## 2.6 Objetivo 6 — comparação com métodos reais

*Comparar a acurácia estimada pelos níveis de Oracle com classificadores individuais e métodos reais de combinação (votação majoritária, média de probabilidades) e, quando viável, DCS/DES.*

Foram medidos 14 fusores nos mesmos 870 folds, com DSEL disjunto e  $k = 7$  vizinhos.




Figura 2: Folga  $\text{Oracle}_1 - \text{MVR}$  por base. A dispersão entre bases (0.017 a 0.458) é muito maior que a dispersão entre modos (0.142 a 0.219): o potencial não explorado é sobretudo uma propriedade do problema, não da estratégia de geração.




Figura 3: Os 14 fusores contra o teto Oracle<sub>1</sub> (tracejado preto) e a acurácia individual média (pontilhado cinza), um painel por modo. A distância da barra mais alta até a linha tracejada é a parte do potencial do pool que nenhum método alcançou. Barra ausente = método inaplicável ao pool.

Tabela 4: Acurácia média dos 14 fusores contra o teto Oracle<sub>1</sub>. Traço = método que exige `predict_proba`, indisponível no Perceptron linear.

| Fusor                                          | GA            | Bagging       | Random Forest |
|------------------------------------------------|---------------|---------------|---------------|
| Votação majoritária (MVR)                      | 0.7784        | 0.8467        | 0.8549        |
| Combinação suave                               | 0.7738        | 0.8466        | 0.8546        |
| OLA                                            | 0.7829        | 0.8028        | 0.7915        |
| LCA                                            | 0.7271        | 0.7878        | 0.7863        |
| MCB                                            | 0.7828        | 0.7943        | 0.7900        |
| Rank                                           | 0.7760        | 0.8022        | 0.7908        |
| KNORA-E                                        | 0.7897        | 0.8261        | 0.8274        |
| KNORA-U                                        | <b>0.8056</b> | 0.8468        | <b>0.8564</b> |
| DES-P                                          | 0.8021        | 0.8481        | 0.8566        |
| DES-KNN                                        | 0.7995        | 0.8477        | 0.8492        |
| META-DES                                       | —             | <b>0.8482</b> | 0.8545        |
| KNOP                                           | —             | <b>0.8486</b> | 0.8556        |
| Melhor individual (estático)                   | 0.7630        | 0.7999        | 0.7958        |
| Seleção estática                               | 0.7797        | 0.8475        | 0.8546        |
| Melhor por fold ( <i>oracle</i> sobre métodos) | 0.8340        | 0.8688        | 0.8733        |
| Acurácia individual média                      | 0.7052        | 0.7931        | 0.7806        |
| Oracle <sub>1</sub>                            | 0.9976        | 0.9951        | 0.9970        |
| Folga Oracle <sub>1</sub> – MVR                | 0.2192        | 0.1484        | 0.1421        |
| <b>Folga recuperada</b>                        | <b>24.0%</b>  | <b>15.0%</b>  | <b>14.2%</b>  |

(a) **O melhor pool produz a pior votação.** O GA tem o *maior* Oracle<sub>1</sub> de todos (0.9976) e a *menor* votação majoritária de todas (0.7784). A folga resultante, 0.2192, é 54% maior que a do Random Forest (Friedman  $p = 0.0045$ ; GA *vs* RF acima da diferença crítica, Wilcoxon  $p = 0.0003$ ). Em P2 o pool contém um classificador correto para *toda* amostra de teste (Oracle<sub>1</sub> = 1.0000), os erros são praticamente independentes ( $DF/e^2 = 1.02$ ) e a votação majoritária entrega 0.5420. Não é falta de informação no pool — é o fusor que não a extrai.

(b) **A combinação suave não supera a votação majoritária em nenhum modo.** Nos pools de árvores as duas regras empatam ( $\Delta$  da ordem de  $10^{-4}$ ; dão o mesmo resultado em 278 e 275 dos 290 folds). No pool de Perceptrons a combinação suave é pior em média ( $-0.0046$ ), mas a diferença **não é estatisticamente significativa** ( $p = 0.51$ ). A conclusão que se sustenta é a negativa: para pools de classificadores lineares a média de margens normalizadas não é o método real a bater — o MVR é.

(c) **O eixo que organiza a seleção dinâmica é a poda.** O resultado mais robusto do experimento não é sobre a folga, é sobre o custo de descartar membros do pool. Testando cada fusor contra o MVR por base ( $N = 29$ ), com correção de Holm para a família de 13 testes:

Em Bagging o padrão é idêntico: OLA, LCA, MCB e Rank perdem em 27–28 das 28 bases, com  $\Delta$  entre  $-0.044$  e  $-0.059$  e  $p_{\text{Holm}} \leq 0.0001$ . A escala é clara:

- podar até *um* classificador (OLA, LCA, MCB, Rank, melhor individual) → perda de 0.044 a 0.069 nos pools de árvores, sempre significativa;
- podar parcialmente (KNORA-E) → perda intermediária, ainda significativa;
- não podar, apenas reponderar (KNORA-U, DES-P, META-DES, KNOP, seleção estática) → empate técnico com o MVR.



Tabela 5: Fusores contra o MVR no pool Random Forest (Wilcoxon pareado, Holm).

| Fusor             | Média  | $\Delta$ vs MVR | Vitórias/derrotas | $p$ (Holm) |
|-------------------|--------|-----------------|-------------------|------------|
| LCA               | 0.7863 | -0.0686         | 0/29              | < 0.001    |
| MCB               | 0.7900 | -0.0649         | 0/29              | < 0.001    |
| Rank              | 0.7908 | -0.0641         | 0/29              | < 0.001    |
| OLA               | 0.7915 | -0.0634         | 0/29              | < 0.001    |
| Melhor individual | 0.7958 | -0.0592         | 1/28              | < 0.001    |
| KNORA-E           | 0.8274 | -0.0275         | 3/24              | 0.0004     |
| DES-KNN           | 0.8492 | -0.0057         | 10/18             | 0.097      |
| KNORA-U           | 0.8564 | +0.0015         | 19/6              | 0.31       |
| DES-P             | 0.8566 | +0.0017         | 13/9              | 0.84       |
| KNOP              | 0.8556 | +0.0006         | 13/12             | 1.00       |
| META-DES          | 0.8545 | -0.0005         | 13/15             | 1.00       |
| Seleção estática  | 0.8546 | -0.0003         | 14/12             | 1.00       |
| Combinação suave  | 0.8546 | -0.0003         | 1/2               | 1.00       |

Os dois métodos estáticos confirmam o eixo pelos extremos: a seleção estática, que mantém o pool inteiro, empata com o MVR nos três modos; o melhor individual, que é poda máxima sem nenhuma localidade, está entre os piores em todos.

**(d) Onde a seleção dinâmica de fato paga.** No pool de Perceptrons a ordem se inverte parcialmente: **KNORA-U é o único fusor que supera o MVR de forma estatisticamente sustentada em algum modo** (+0.0272,  $p_{\text{Holm}} = 0.0045$ , vencendo em 147 dos 290 folds contra 49 derrotas e 94 empates). Nos pools de árvores o mesmo método fica em +0.0001 e +0.0015, sem significância.

A vantagem se concentra nas bases de fronteira não-linear em baixa dimensão: em P2, Lithuanian e Banana a recuperação média do GA é 0.766, contra 0.157 do Bagging e 0.155 do Random Forest nas mesmas bases. O mecanismo é geométrico: um Perceptron não separa a espiral do P2, mas separa qualquer vizinhança dela, e escolher o Perceptron certo por região é exatamente o que falta. Uma árvore já resolve a fronteira sozinha, então o voto majoritário já está perto do que o pool consegue e não sobra folga *local* a extrair.

**(e) O viés de estimação foi medido, não apenas discutido.** Numa versão anterior do protocolo o DSEL da seleção dinâmica era a mesma partição que o GA usa na função de *fitness*, o que favorecia o GA por construção. O protocolo atual separa as duas partições. Isolar o viés exige separar dois efeitos simultâneos — o viés removido (só afeta o GA) e o DSEL pela metade (afeta os três modos) — e Bagging e RF servem de grupo de controle, porque mantêm os pools *bit-idênticos* entre os dois desenhos (verificado:  $\max |\Delta| = 0.000000$  em toda coluna de pool e curva Oracle idêntica em 290/290 folds de cada modo).

Pela diferença-em-diferenças, restrita aos cinco métodos comuns aos dois desenhos: o controle perdeu -0.0057 de folga recuperada, o GA perdeu -0.0003, logo o viés é +0.0055 — cerca de 3% relativos, e nenhum dos deltas é significativo. O desenho anterior **não** estava inflando materialmente a vantagem do GA; a correção está feita e é a que vale, mas não muda conclusão alguma.

## 2.7 Objetivo 7 — níveis intermediários são um limite mais realista?

*Analisar se níveis intermediários de Oracle podem representar estimativas de limite superior mais conservadoras e mais próximas do desempenho de métodos reais.*

**A resposta é não**, e o experimento identifica a razão estrutural.

Defina  $N^*$  como o menor  $N$  tal que  $\text{Oracle}_N < \text{votação majoritária}$  — o nível em que o Oracle deixa de ser otimista.

Tabela 6:  $N^*$  por modo, com  $M = 100$ .

| Modo          | Mediana | IQR      | Média | Folds com $N^* > 50$ |
|---------------|---------|----------|-------|----------------------|
| GA            | 52      | [51, 55] | 51.9  | 79.3%                |
| Bagging       | 53      | [51, 56] | 54.4  | 81.4%                |
| Random Forest | 53      | [51, 56] | 53.0  | 79.3%                |

Friedman  $p = 0.40$ : **os três modos têm o mesmo  $N^*$ , e ele fica em  $N \approx M/2$** . Não é coincidência empírica — é quase uma identidade. Em problema binário com  $M = 100$ , “a votação majoritária acerta” equivale a “pelo menos 51 classificadores acertam”, ou seja  $\text{Oracle}_{51} \equiv MVR$  por construção; 22 das 29 bases são binárias.

Disso decorre a resposta ao objetivo:

- Para  $N \ll M/2$  a curva está **saturada**: os três modos ficam entre 0.988 e 0.998 em  $N = 1..5$ , e  $\text{Oracle}_5 \geq MVR$  em 100% dos 870 folds. As diferenças entre modos são estatisticamente reais ( $p < 0.001$ ) mas de magnitude 0.002–0.004. Mais conservador que  $\text{Oracle}_1$ , sim; perto de um método real, não.
- Para  $N \approx M/2$  a curva **já é** a votação majoritária, sob outro nome. Não acrescenta informação.
- **Não existe faixa intermediária útil** entre as duas.




Figura 4: Distribuição de  $N^*$ . A concentração em torno de  $M/2$  nos três modos é o que impede qualquer nível intermediário de servir como limite realista.

**O que substitui a ideia original.** O objetivo 7 buscava uma estimativa conservadora e alcançável. Ela existe, mas não é “ $\text{Oracle}_N$  para algum  $N$ ”; é a folga  $\text{Oracle}_1 - MVR$  ponderada pela fração dela que métodos reais recuperam. Medido: mesmo tomando o melhor de dez métodos dinâmicos escolhido *a posteriori* no teste, a recuperação fica em 24.0% (GA), 15.0% (Bagging) e 14.2% (RF), com medianas bem menores (0.167, 0.108, 0.091) e recuperação *exatamente zero*

no primeiro quartil de Bagging e RF. Um limite superior operacional e honesto para um pool de árvores é, portanto,

$$MVR + 0.15 (\text{Oracle}_1 - MVR), \quad (4)$$

e ainda assim otimista, porque o numerador usa escolha de método no teste.

**Robustez à métrica.** A metodologia do subprojeto pede precisão, revocação, F1 e acurácia balanceada além da acurácia — a preocupação legítima sendo que a acurácia bruta esconda a classe minoritária, num catálogo que chega a IMB 71.5. As quatro métricas foram gravadas para *todo* fusor. Em acurácia balanceada tudo cai, mas de forma quase uniforme, e a folga *crece*:

Tabela 7: Acurácia *versus* acurácia balanceada.

| Modo          | Oracle <sub>1</sub> | Oracle <sub>1</sub> balanc. | MVR    | MVRbalanc. | Folga  | Folga balanc. |
|---------------|---------------------|-----------------------------|--------|------------|--------|---------------|
| GA            | 0.9976              | 0.9967                      | 0.7784 | 0.7368     | 0.2192 | 0.2599        |
| Bagging       | 0.9951              | 0.9923                      | 0.8467 | 0.8163     | 0.1484 | 0.1760        |
| Random Forest | 0.9970              | 0.9949                      | 0.8549 | 0.8214     | 0.1421 | 0.1735        |

O Oracle<sub>1</sub> é quase insensível ao desbalanceamento — basta *um* classificador do pool acertar a instância minoritária — enquanto o MVR precisa que 51 acertem, e é aí que a minoria se perde. Nos *rank*s de fusor a única mudança sistemática é o DCS puro melhorar 0.3–0.4 posições (OLA vai de *rank* 6.38 para 6.00 no RF), o que faz sentido — escolher o competente na vizinhança ajuda numa região minoritária. Mas em nenhum modo isso muda o topo: KNORA-U, META-DES, MVR e combinação suave continuam empatados na frente, e OLA e LCA continuam no fundo. **Nenhuma conclusão deste relatório depende da escolha da métrica.**

## 2.8 Objetivo 8 — recomendações e redução de custo

*Gerar recomendações sobre o uso de Oracles em diferentes níveis como ferramenta de análise prévia do potencial de desempenho de ensembles, considerando a redução de custo computacional.*

A base quantitativa da recomendação é que o índice de redundância prevê a folga *antes* de treinar qualquer método de seleção:

$$\text{Spearman}(\text{DF}/e^2, \text{Oracle}_1 - MVR) = -0.860, \quad p = 8 \times 10^{-27}, \quad n = 87. \quad (5)$$

Por modo: GA −0.933, Bagging −0.909, RF −0.785. O índice custa  $O(M^2n)$  sobre a matriz de acertos que já se tem.

As sete recomendações que o experimento sustenta:

1. **Use Oracle<sub>1</sub> − MVR como medida de potencial, não Oracle<sub>1</sub> como meta.** O Oracle<sub>1</sub> fica entre 0.995 e 0.998 nos três modos e 29 bases: não discrimina. A folga discrimina (0.142 a 0.219 entre modos; 0.017 a 0.458 entre bases).
2. **Não procure um Oracle<sub>N</sub> intermediário como limite realista.**  $N^*$  fica em  $N \approx M/2$  nos três modos (Friedman  $p = 0.40$ ). Reporte Oracle<sub>1</sub>, a folga e  $N^*$  como diagnóstico; não reporte um nível intermediário como cota.
3. **Calcule DF/ $e^2$  antes de treinar qualquer método de seleção.** Regra operacional medida neste experimento:

| DF/ $e^2$   | Folga típica | Decisão                                          |
|-------------|--------------|--------------------------------------------------|
| $\geq 4$    | $< 0.05$     | não vale DCS/DES — o custo não se paga           |
| 2–4         | 0.05–0.15    | marginal; só KNORA-U ou DES-P, sem esperar ganho |
| $\approx 1$ | $> 0.30$     | candidato forte, sobretudo com base fraco        |




Figura 5: À esquerda, a distribuição da folga recuperada por modo. À direita, a mesma quantidade contra  $DF/e^2$ : a correlação que prevê o *tamanho* da folga não prevê a *fração alcançável*.

Extremos observados: Thyroid ( $DF/e^2$  entre 6.96 e 8.58, folga 0.035) contra P2 ( $DF/e^2 = 1.02$ , folga 0.458).

4.  **$DF/e^2$  não prevê o que você vai recuperar.** Ele prevê a folga, não a fração alcançável (por base  $\rho = +0.19$ ,  $p = 0.074$ ; por fold  $\rho = +0.02$ ,  $p = 0.59$ ). São perguntas distintas. Para prever recuperação, o preditor que funcionou é qualitativo: fronteira não-linear em baixa dimensão *mais* classificador-base fraco.
5. **Se for usar seleção dinâmica, use um método que não pode o pool.** OLA, LCA, MCB, Rank e o melhor individual perdem de 0.044 a 0.069 contra o MVR nos pools de árvores, em 27–29 das 29 bases, com  $p_{\text{Holm}} < 0.001$ . KNORA-U é o único que supera o MVR de forma sustentada em algum modo e nunca perde em nenhum.
6. **Em pool homogêneo forte (Bagging, Random Forest) a decisão padrão é não usar DCS/DES.** Nenhum dos 13 fusores supera a votação majoritária de forma significativa em nenhum dos dois modos. O melhor caso é +0.0019 (KNOP em Bagging), que não sobrevive a Holm. O MVR é grátis; os outros não.
7. **O custo foi medido, não estimado.** Passar de 5 para 12 métodos de seleção levou o experimento de 2h21 para 4h08 de relógio nas mesmas 29 bases  $\times$  10 folds  $\times$  3 modos — fator 1.76 $\times$ . Combinado com a recomendação 6: o custo marginal de DCS/DES é da ordem do custo de gerar os pools, e num pool de árvores ele compra zero.

### 3 Confronto com os resultados esperados

| Esperado no projeto                                                                       | Obtido                                                                                                                                                                                                                                                         |
|-------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Caracterizar quantitativamente $\text{Oracle}_N$ em múltiplos níveis e construir a curva. | Confirmado. Curva completa $N = 1..M$ por fold, monotonicidade em 870/870, e a identidade que liga a média da curva à acurácia individual.                                                                                                                     |
| Verificar se níveis intermediários se aproximam de métodos práticos.                      | <b>Refutado</b> , com mecanismo identificado: $N^* \approx M/2$ porque $\text{Oracle}_{M/2+1} \equiv \text{MVR}$ em problema binário. Abaixo disso a curva está saturada. Resultado negativo, mas informativo — fecha a pergunta em vez de deixá-la em aberto. |

| Esperado no projeto                                                                                                                     | Obtido                                                                                                                                                                                    |
|-----------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Implementação reprodutível de Oracle <sub>1</sub> .Oracle <sub>M</sub> , com scripts de treino, matriz de acertos, métricas e gráficos. | Entregue. Manifesto por fold com <i>git SHA</i> , versões de dependências e sementes; 8 figuras e testes estatísticos gerados por um único comando.                                       |
| Relacionar diversidade, redundância de acertos e desempenho.                                                                            | Entregue e quantificado: $DF/e^2$ prevê a folga com $\rho = -0.86$ ( $n = 87$ ), e o mesmo índice <i>não</i> prevê a fração recuperável — distinção que não estava antecipada no projeto. |
| Indicar em que cenários o Oracle tradicional superestima o desempenho alcançável.                                                       | Entregue: superestima sempre, e mais ainda em pools diversos de base fraco. Entre 76% e 86% da folga anunciada não é recuperada nem pelo melhor de dez métodos escolhido no teste.        |
| Apoiar a decisão sobre usar métodos complexos de seleção.                                                                               | Entregue como as sete recomendações operacionais, com um limiar numérico em $DF/e^2$ e um critério qualitativo para prever recuperação.                                                   |

## 4 Limitações

- **Bases de imagens.** O objetivo 5 as menciona como preferência; o catálogo atual privilegia comparabilidade com a literatura de referência. É a pendência mais direta.
- **$M = 100$  fixo.** Todas as conclusões sobre  $N^*$  são relativas a  $M = 100$ . O argumento estrutural (Oracle <sub>$M/2+1$</sub>   $\equiv$  MVR em problema binário) é independente de  $M$ , mas a verificação empírica não varreu  $M$ .
- **Dois métodos ausentes no pool do GA.** META-DES e KNOP exigem `predict_proba`, indisponível no Perceptron linear. As colunas ficam vazias com o motivo gravado por fold, e as comparações entre modos que os envolvem foram restritas aos modos aplicáveis — não houve imputação.
- **“Melhor por fold” é otimista.** A métrica de folga recuperada usa o máximo entre métodos escolhido no conjunto de teste. Um seletor de método honesto entregaria menos. Os números de recuperação são cotas superiores.
- **Poder estatístico com 14 fusores.** A diferença crítica de Nemenyi cresce com o número de colunas a ponto de nada ser significativo. Por isso o protocolo mantém um conjunto primário de 7 métodos para Friedman/Nemenyi e trata os demais em camada descritiva, com Wilcoxon pareado contra o MVR e correção de Holm.

## Referências

- CRUZ, R. M. O.; SABOURIN, R.; CAVALCANTI, G. D. C. Dynamic classifier selection: Recent advances and perspectives. *Information Fusion*, v. 41, p. 195–216, 2018.
- CRUZ, R. M. O.; SABOURIN, R.; CAVALCANTI, G. D. C. META-DES.Oracle: Meta-learning and feature selection for dynamic ensemble selection. *Information Fusion*, v. 38, p. 84–103, 2017.
- DEMŠAR, J. Statistical Comparisons of Classifiers over Multiple Data Sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.

- KUNCHEVA, L. I.; WHITAKER, C. J. Measures of Diversity in Classifier Ensembles and Their Relationship with the Ensemble Accuracy. *Machine Learning*, v. 51, p. 181–207, 2003.
- SOUZA, M. A.; CAVALCANTI, G. D. C. On the Characterization of the Oracle for Dynamic Classifier Selection. In: *IJCNN*, 2017, Anchorage. p. 332–339.